

after_SVAMP 备忘录

SVAMP 外延实验完成后的综合分析与下一步路线

归档版本

我把你这次给的三部分放在一起看了：外延实验前的论文、事先写好的结果整合计划、以及现在完整的 **output.zip**。结论比单看 Program 09 的 PASSED 更重要：

这轮外延实验是成功的，而且成功的方式非常适合这篇论文。现在的大规模数值实验基本可以结束了；真正剩下的是把已经得到的证据“正确地写进论文”，以及补一个低成本的 **mechanism post-processing**。

原论文在做 SVAMP 前最大的实证短板非常明确：只有一个小模型、一个 GRPO 配置、GSM8K 和三个 seed，因此当时非常谨慎地明确写着“不主张 cross-dataset robustness”，而且把 external prompt-distribution robustness 留在 evidence 之外。你事先写的 memo 恰好把 Program 08 定位成 frozen external falsification test，而不是“再多跑一个 dataset”：pair、estimator、gate、scoring protocol 都不根据 SVAMP 重调。现在实际结果正好验证了这个设计的价值。

1. 最重要的结果：SVAMP 实际上把三层问题都回答了

你事先锁定的解释规则是非常好的：Level 1 看 structural transfer，Level 2 看 refresh transfer，Level 3 看 decision-rule transfer。我直接从 T08_svamp.csv 去重并重新计算了一遍，结果如下。

预先定义的层级	SVAMP 实际结果	我的判断
Structural transfer	low rESS mean 0.1378 ; medium 0.2118 ; high 0.9743	非常强
Matched refresh: overlap	old 0.1420 → 0.9651 ; 6/6 recent 更高	非常强
Matched refresh: abs. discrepancy	0.00856 → 0.00230 , 下降约 73.1% ; 5/6 改善	强 replication
Matched refresh: RMSE	0.01030 → 0.00254 , 下降约 75.3%	与 shared-reference squared-discrepancy theory 非常吻合
Frozen rESS gate @1%	接受 24/24 ; false accept 6/24 = 25%	强 negative result
Frozen rESS gate @2%	接受 24/24 ; false accept 1/24 = 4.17%	gate 仍不是 certificate
Frozen rESS gate @5%	接受 24/24 ; false accept 0	tolerance 变宽后 failure region 消失

这里最漂亮的是：三个 seed 分别看，**high > medium > low** 的 **band-average ordering** 都保持了。而且 high-overlap 的数值几乎没有因 GSM8K → SVAMP 而崩掉：SVAMP high overlap 的平均 rESS 仍达到约 0.974。

这意味着你的论文已经不再只能说：

“在 GSM8K 中旧 trace 会 stale。”

而可以相当稳妥地升级成：

由 **checkpoint drift** 产生的 **overlap structure** 在一个冻结的外部 **prompt distribution** 上仍然转移。

这正是 memo 当初认为比 “SVAMP accuracy 好不好” 重要得多的结果。

2. matched refresh 的外部复制尤其漂亮

原论文目前最强的 GSM8K test 结果是：

- rESS: 0.127 -> 0.959
- 9/9 overlap improved
- absolute reference discrepancy: 0.005866 -> 0.001642
- 8/9 improved。

现在 SVAMP 中真正可以形成 same-target old/recent matched comparison 的冻结 pairs 有 **6 个**。这六个得到：

mean median-rESS:
0.14197 -> 0.96508

mean absolute reference discrepancy:
0.008557 -> 0.002300

RMSE:
0.010296 -> 0.002541

而且：

rESS improves: 6 / 6
abs discrepancy improves: 5 / 6

这和 GSM8K 的：

9 / 9
8 / 9

结构几乎是一个非常漂亮的 replication。

尤其有意思的是，SVAMP 同样出现了一个 **overlap** 极大改善但 **realized absolute discrepancy** 没有改善的 **pair**。这不是坏消息，反而和你论文现有理论的核心完全一致： κ_2 只是 overlap channel，而风险还取决于 reward-residual allocation A_μ ；所以 “rESS $\uparrow$ ” 不等于 “每一个 realized discrepancy 必须 $\downarrow$ ”。原论文已经非常谨慎地这么写了。

因此，这次外延实验没有把理论搞简单，反而让理论更可信。

3. 我认为最有发表价值的结果甚至可能是 **gate** 的失败

GSM8K official test 原本已经是：

```
acceptance = 100%  
false accept @ 1% = 15.2%
```

所以文章说 scalar rESS threshold 并不能形成 tight discrepancy-safe reuse boundary。

现在 frozen gate 原封不动搬到 SVAMP：

```
acceptance = 100%  
false accept @ 1% = 25.0%  
false accept @ 2% = 4.17%
```

这个结果其实比 “gate 在 SVAMP 也很好” 更有论文味道。

因为它说明：

gate 的 failure 不是 GSM8K official test 的偶然现象。

更准确地说：

overlap 是非常稳定的 evidence-quality coordinate,
但一个 frozen scalar rESS threshold 不是跨 prompt distribution 的 discrepancy certificate。

这正是你事先 memo 里说的最理想的 negative result 类型：如果 SVAMP 中 frozen gate 仍失败，那么 weight-only gate 的不足就不再像是 GSM8K 的特殊现象。

而且这产生了一个非常漂亮的论文结构：

mechanism transfers; simple decision rule does not.

这比 “所有东西都成功” 更有深度。

4. 另一个值得保留但不要抢主线的结果：IS vs pWIS

我也把 SVAMP 的 24 个 frozen cases 中 IS 和 pWIS 重新汇总了一遍：

	MAE	RMSE
IS	0.004996	0.006262
prompt-WIS	0.007102	0.009266

但在 **high-overlap band**：

IS MAE	0.002707
pWIS MAE	0.002669

两者几乎一样。

真正把 pWIS MAE 拉坏的是 low/medium overlap。

这和现有 Section 6.3 的论述非常兼容：你选择 pWIS 是因为它匹配 prompt-grouped estimand，并没有声称 pWIS 在每个有限样本里都优于 ordinary IS。

所以我的建议是：不要把 **SVAMP IS-vs-pWIS** 升成新的正文故事。Appendix 报即可。它主要用于证明你没有 cherry-pick estimator performance。

5. Program 09 本身：我现在比刚才更放心

我不仅看了 PROGRAM 09 PASSED，还直接审计了 zip 里的 manifest。

几个很重要的事实：

```
Program08 manifest SHA-256
93e91399b5f03596fc7d9fb8f604a83ae26ca349dac93ce2568b60a2321096
```

与 Program 09 manifest 中记录的完全一致。

paper_values.json 的 SHA-256 我重新算了一遍，也和 manifest 中的：

```
5e106ad10f6991fe652e59a1de96f16e1076bb6237a22c652f0a5db2c18bbdfd
```

完全一致。

另外，Program 09 manifest 记录了 **31 个生成的 paper artifacts**。我逐一重新计算 SHA-256：

```
31 / 31 found
31 / 31 hash matched
0 missing
0 mismatch
```

所以从 evidence provenance 的角度，现在这条链已经相当干净：

```
Program 08 raw SVAMP result
  |
  v
Program 08 manifest
  |
  v
Program 09 deterministic paper layer
  |
  v
paper_values / tables / figures
  |
  v
paper_output_manifest
```

而且 Program 09 manifest 明确记录：

```
calls_model          = False
refits_gate          = False
mutates_upstream_results = False
paper_numbers_hand_copied = False
```

这正是你 memo 当初要求的 final evidence freeze。

所以 01-09 的大实验链我现在认为可以冻结。不要再为了“更完整”去重新跑。

6. 但是：Program 09 目前还没有把 SVAMP 的学术价值完全“出版化”

这是我这次检查发现的最重要缺口。

Program 09 的确已经把 SVAMP 纳进来了：

```
T08_svamp_present = True
```

而且：

Table3_frozen_gate_validation 已经增加了 SVAMP；

Appendix_svamp_pair_results 已经生成。

但是，你事先 **memo** 中最重要的两项还没有真正生成：

```
main-text external robustness summary table
main-text SVAMP transfer figure
```

你事先计划的是一个正文 summary table，把 GSM8K official test 和 SVAMP external 并列，并加一个 Figure 6 显示 overlap-band transfer / matched refresh。

而当前 manifest 明确：

```
Figure6_generated = False
```

同时 paper_values.json 里虽然已经有 SVAMP gate：

```
gate_svamp_external_prompt_distribution...
```

却没有我刚才算出的这些非常关键的 external metrics：

```
SVAMP low / medium / high rESS
SVAMP old -> recent rESS
SVAMP old -> recent MAE
SVAMP old -> recent RMSE
6/6
5/6
```

这意味着：如果我们现在直接写论文，这些数字就只能人工从 T08 复制进去。

我不建议这么做。

你自己的论文原则已经是：

raw outcome → deterministic paper layer → LaTeX/PDF

所以这最后一块也应该遵守同样原则。

7. 我发现两个小但真正需要修的 **publication-format** 问题

这不是数值问题，也完全不需要重跑实验。

第一，Program 09 自动生成的：

Appendix_svamp_pair_results.tex

现在把 seed 打成了：

2.026e+07

这样三个：

20260826
20260827
20260828

在排版后基本无法区分。

behavior/target step 也出现：

0.0000
300.0000

这种格式作为 machine table 没问题，作为论文 table 不专业。

第二，更重要的是，Program 09 的自动表头还写：

absolute error
mean absolute error

但你的论文已经非常严格地区分：

finite on-policy comparison = **reference discrepancy**
theoretical deviation from V_n = **error**

因此最终论文表头应该显示：

absolute reference discrepancy
mean absolute reference discrepancy

内部 CSV 字段仍然叫 absolute_error 没关系，出版层必须换显示名称。

8. α / reward-stratum analysis: 我现在仍然强烈建议做

这一点在看到 SVAMP 结果以后, 我反而比 memo 写的时候更赞成。

原论文已经有:

$$m_2 = \kappa_2 A_\mu$$

以及 binary reward:

$$A_\mu = v^2 + (1 - 2v)\alpha_\mu.$$

但目前实证主要真正观察的是 overlap / κ_2 通道。论文自己也承认当前 numerical results 没有 confirmatorily estimate α_μ , 并把它留作 post-hoc mechanism diagnostic。

事先 memo 对这一点的 protocol 也处理得很正确: development 做主要 exploratory analysis, official test 只能叫 exploratory replication, 绝不能倒过来说是 confirmatory test。

SVAMP 现在又出现:

6/6 rESS improves

5/6 discrepancy improves

于是那个唯一例外正好强化了这个问题:

是不是 κ_2 大幅改善, 但是 α / reward alignment 朝反方向动了一点?

如果现有 completion-level rescoring artifacts 保留:

W_ij
R_ij

那么这完全是**离线 post-processing**, 不需要再调用模型。

而且 SVAMP 的 target reference value 大致只有 0.12–0.19, 明显:

$$v < \frac{1}{2}.$$

所以这里的解释方向也非常清楚:

$$\frac{\partial m_2}{\partial \alpha} = \kappa_2(1 - 2v) > 0.$$

即在这些目标下, 其他条件相同, 较低的 α 对 leading variance factor 更有利。

这个分析如果做得好, 会把现在的:

“理论有一个 reward-stratum decomposition”

升级成:

“我们实际观察 refresh 时 overlap channel 与 reward-allocation channel 怎样共同运动。”

它是现在唯一一个我认为仍值得补的科研分析。

9. 所以我现在对整篇论文的判断

原稿其实已经不是弱稿。它最好的地方是它一直非常克制：标准 SNIS 理论和你真正新增的 trace-reuse-specific consequences 分得很清楚；shared finite-reference 的语言也非常严谨；并没有把 empirical rESS 当成 universal certificate。

Program 08 以后，这篇文章真正发生的变化不是：

“20 页论文多了一个 SVAMP 数据集。”

而是 evidence architecture 从：

```
development
  |
  v
held-out seed
  |
  v
official GSM8K test
```

变成：

```
development
  |
  v
held-out seed
  |
  v
official GSM8K test
  |
  v
frozen external prompt distribution
```

这正是你之前 memo 认为比“再加 theorem”更能说服 reviewer 的结构。

而且 external experiment 给出的故事非常干净：

overlap structure transfers strongly; matched refresh transfers strongly; scalar decision certificate does not.

我认为这是比“SVAMP 所有东西都完全复制 GSM8K”更有学术内容的结果。

10. 现在最合理的下一步

我不建议修改或重跑 **Program 09**。它现在已经形成一个干净的 frozen evidence layer。

我建议下一步建立一个很小的、纯确定性的 **Program 10**，例如：

```
10_make_final_integration_outputs.py
```

它只读取已有的：

```
T02  
T04  
T08  
Program09 paper outputs
```

绝不调用模型，绝不改 gate，绝不改 pair，只做最终 manuscript integration。它应该生成：

```
External_robustness_summary.csv/.tex  
Figure6_svamp_transfer.pdf/.png  
external_values.json/.tex  
final_integration_manifest.json
```

其中自动固定我们刚才得到的：

```
0.1378 / 0.2118 / 0.9743  
0.1420 -> 0.9651  
0.00856 -> 0.00230  
0.01030 -> 0.00254  
6/6  
5/6  
25%  
4.17%
```

这样最终论文中仍然一个数字都不用手抄。

然后再做一次 $\hat{\alpha}$ 的 exploratory post-processing；如果现有 artifacts 足够，就纳入 Discussion/Appendix；如果现有 artifacts 不足，我反而倾向于不再为它启动昂贵的新模型计算。

最后才进入真正的论文改写。

所以我现在给这个项目的状态判断是：

大型实验：完成。

SVAMP external validation：结果很好。

Program 09 evidence freeze：通过，而且我核过 hashes。

科研上剩余：一个低成本 α mechanism analysis。

出版上剩余：一个 **deterministic integration layer** + 修改论文。

而且现在已经可以把原论文 Limitations 那句 “external prompt-distribution robustness is outside the reported evidence” 正式删掉，换成你 memo 里那种更准确的表述：

The frozen SVAMP experiment extends the evidence across prompt distributions, but not across model scales, training algorithms, reward types, or independently trained task-specific policies.

我认为我们下一步最应该做的就是这个 **Program 10**，而不是再跑任何新的大型实验。