

备忘录：Program 08 与后续数值结果的最大化学术价值整合方案

post_numres

可以。现在最重要的原则是：**Program 08** 以及后续尚未完成的分析出来以后，不应该简单地“多加一个数据集、多加几张表”，而应该利用这些结果把 **v10** 现有的三条理论机制真正闭环：时间累积、**reward-stratum allocation**、**measurement/reference noise**。

目前正文的主证据仍然是 GSM8K: fixed-log frontier、matched refresh、estimator comparison 和 frozen scalar gate；其中 matched refresh 是最强结果，官方 test 上 rESS 9/9 改善、absolute reference discrepancy 8/9 改善。当前 Limitations 也明确说尚不主张 cross-dataset robustness，所以 Program 08 一旦完成，最有价值的作用就是**把这一项 limitation 变成一个预先冻结、真正独立的 external robustness test**，而不是把 SVAMP 当成又一个普通实验。

我建议最终按下面这套方案整合。

1. Program 08 的最高学术价值不是“第二个数据集”，而是 external falsification test

Program 08 的价值很特殊，因为它具有几个很好的属性：

- frozen gate 没有根据 SVAMP 调整；
- representative pairs 在看 SVAMP outcome 前确定；
- GSM8K 是训练/主分析域；
- SVAMP 是新的 prompt distribution；
- target checkpoints、behavior checkpoints、OPE estimator、importance-weight definition 都保持原协议；
- 所以它不是“再拟合一次”，而是真正的 **out-of-domain robustness / falsification test**。

因此最终文章不要写：

“We additionally evaluate on SVAMP.”

应该写成：

External prompt-distribution stress test. We transfer the frozen trace-reuse protocol—checkpoint pairs, probability scoring, estimator, and gate—without re-fitting to SVAMP.

这一个定位变化非常重要。

如果 Program 08 成功，它回答的是：

GSM8K 上发现的 trace-reuse mechanism 是否跨 prompt distribution 保持？
--

而不是：

SVAMP 准确率怎么样？

2. Program 08 出结果后，正文只新增一个主要 Results subsection

我建议不要把当前 Section 6 打散。

现有：

- 6.1 Fixed historical log
- 6.2 Matched refresh
- 6.3 IS vs pWIS
- 6.4 frozen gate

都保留。

然后新增：

6.5 External prompt-distribution robustness on SVAMP

这一节控制在 约 1–1.5 页。

它只回答四个问题，而且顺序固定：

第一：GSM8K 冻结的 overlap ordering 是否转移？

Program 08 已经预先把代表 pairs 分成：

low overlap, medium overlap, high overlap.

所以首先检查 SVAMP 上是否仍然：

$$rESS_{\text{high}} > rESS_{\text{medium}} > rESS_{\text{low}}.$$

这是最干净的 external-validation outcome。

如果成立，就意味着：

checkpoint-derived evidence staleness is not merely a GSM8K test-set artifact.

这一点比单报 MAE 更有价值。

第二：recent behavior 是否继续修复 overlap?

这里应该复刻文章最强的 matched-refresh logic。

不要关注所有 24 cases 的平均值先。

最重要的是：

old log vs recent log

对于同一个 target:

$$\Delta rESS.$$

如果 SVAMP 仍表现为：

$$rESS_{\text{recent}} > rESS_{\text{old}},$$

那么会形成：

GSM8K development → GSM8K official test → SVAMP external prompts

三层 replication。

这会显著提升论文可信度。

第三：overlap repair 是否继续对应 discrepancy improvement?

这里仍然必须保持 v10 的语言纪律。

报告：

$$|\hat{V}_{\text{pWIS}} - \hat{V}_{\text{ref}}|,$$

不要突然又写成 exact error。

因为 SVAMP reference 同样是 finite Monte Carlo。

主要报告：

- mean absolute discrepancy;
- signed discrepancy;
- RMSE / mean squared discrepancy;
- recent better than old 的 pair count。

其中我尤其建议加入 **RMSE / mean squared discrepancy**，因为 v10 的 shared-reference Lemma 对应的是 squared discrepancy，而不是 absolute discrepancy。

这样理论和实证真正对齐：

$$E\left[(\hat{V}_s - \hat{V}_{\text{ref}})^2\right] = \text{MSE}(\hat{V}_s) + \text{Var}(\hat{V}_{\text{ref}}).$$

当前文章已经明确说明 shared finite reference 的 variance 在 expected squared old-vs-recent comparison 中抵消，而 realized absolute ordering 仍可能改变。

所以 SVAMP table 最好同时给：

MAE 和 RMSE.

第四：GSM8K 上冻结的 gate 是否 transfer?

这一点千万不能调参。

Program 08 应该直接报告：

accept rate, false-accept rate, accepted discrepancy

在原来的：

$\epsilon = 0.01, 0.02, 0.05$

下。

如果 gate 在 SVAMP 仍失败：

这反而是一个很强的跨域 negative result: scalar weight-only gate 的不足不是 GSM8K 特例。

如果 gate 在 SVAMP 意外表现很好：

也不要说 “gate validated”。

应该写：

its selectivity is distribution-dependent.

因为 GSM8K official test 已经出现 100% acceptance、1% tolerance 下 15.2% false acceptance。两种情况都具有学术价值。

3. Program 08 最终最好只新增一张主表 + 一张主图

不要因为算了很多数据就把全部塞进正文。

新 Table 5: External robustness summary

我建议结构如下：

Quantity	GSM8K official test	SVAMP external
Number of frozen cases	...	...
Low-overlap median rESS	...	...
Medium-overlap median rESS	...	...
High-overlap median rESS	...	...
Old-log mean abs. discrepancy	...	...
Recent-log mean abs. discrepancy	...	...
Old-log RMSE	...	...
Recent-log RMSE	...	...
Refresh improves rESS	9/9	x/y
Refresh lowers abs. discrepancy	8/9	x/y
Frozen gate FA @ 1%	15.2%	...

这张表会非常强。

因为它不是一个 SVAMP-only table, 而是:

in-domain confirmatory evidence	vs	external transfer evidence
---------------------------------	----	----------------------------

直接比较。

新 Figure 6: SVAMP frozen-pair transfer

我不建议再画 3-4 张复杂图。

最优 Figure 6 可以有两个 panel:

左:

overlap band → median rESS

比较 low / medium / high。

右:

matched old vs recent:

$$x = \text{old rESS}, \quad y = \text{recent rESS}.$$

或者如果 matched refresh case 足够:

左: old-vs-recent discrepancy scatter 右: old-vs-recent rESS scatter

跟 GSM8K Figure 4 保持完全相同视觉语法。

这种图比重新发明新图更有力量, 因为 reviewer 可以直接视觉比较两个数据域。

4. 如果 SVAMP 结果非常好, Abstract 应该怎么升级

现在 Abstract 的核心仍然只报告 GSM8K。当前版本明确写 official GSM8K test 上 rESS 0.127→0.959、discrepancy 0.00587→0.00164, 以及 gate false-accept 15.2%。

SVAMP 出来后, 不应该再塞一堆数字。

最多增加一句：

A frozen external evaluation on SVAMP preserves the qualitative overlap ordering and [if true] the benefit of matched log refresh without pair reselection or gate refitting.

如果结果特别漂亮，可以给一个最有代表性的数值。

但不要让 Abstract 变成：

GSM8K 数字 + SVAMP 数字 + gate 数字 + alpha 数字。

主故事仍然是 GSM8K controlled audit; SVAMP 是 external stress test。

5. Introduction 的升级重点：从“一个 controlled study”变成“两阶段 evidence architecture”

现在 v10 的 Introduction 已经很强调：

fixed-log aging → matched refresh → frozen gate.

将来只需要新增一小段：

The study follows a two-stage evidence design. GSM8K development and official test establish the controlled trace-reuse phenomenon; a separately frozen SVAMP evaluation then tests whether the same overlap structure transfers under prompt-distribution shift without revising checkpoint pairs, estimators, or gate parameters.

这样文章的实验设计层级会非常清晰：

development → held-out seed → official test → external distribution

这是非常有价值的 evidence progression。

6. 最值得补的“非 Program 08”分析： $\hat{\alpha}$

这一项我仍然认为优先级非常高。

因为 v10 已经建立：

$$m_2 = \kappa_2[v^2 + (1 - 2v)\alpha_\mu].$$

但目前实验主要验证的是：

κ_2

这一通道。

文章目前已经定义了 future diagnostic:

$$\hat{\alpha}_i = \frac{\sum_j W_{ij}^2 R_{ij}}{\sum_j W_{ij}^2},$$

并明确说它尚未作为 frozen confirmatory gate 使用。

所以 Program 08 之后, 我认为最值得运行的不是另一个新模型程序, 而是一个很小的 **post-processing** 程序:

对现有 GSM8K development matched pairs 计算:

$$\hat{\alpha}_{\text{old}}, \quad \hat{\alpha}_{\text{recent}}.$$

同时计算:

$$\hat{v}_{\text{ref}},$$

然后构造:

$$\hat{A} = \hat{v}_{\text{ref}}^2 + (1 - 2\hat{v}_{\text{ref}})\hat{\alpha}.$$

这样可以观察 refresh 的两个理论通道:

$$\frac{\hat{\kappa}_r}{\hat{\kappa}_o}$$

以及:

$$\frac{\hat{A}_r}{\hat{A}_o}.$$

7. $\hat{\alpha}$ 最佳发表方式: **development** 为主, **test** 只 **exploratory**

这里科研协议一定要处理干净。

因为这个分析是在看到 official GSM8K results 后才提出的。

所以:

development data

可以把 45 matched pairs 全部分析。

标题:

Post-hoc mechanism analysis of reward-stratum allocation

明确标记 exploratory。

official test

可以计算那 9 cases, 但只能说:

exploratory replication.

不能改口说:

confirmatory validation of Proposition 4.

这一点一定不要破坏。

8. $\hat{\alpha}$ 最有价值的不是“显著不显著”，而是区分三种机制

未来结果可能出现三种非常有意思的情况。

情况 A: κ 大幅改善, α 几乎不动

那说明:

refresh 的主要作用是恢复 support

reward-stratum 是二阶修正。

这是很干净的结果。

情况 B: κ 和 α 都朝降低风险方向走

那么:

refresh 同时修复 overlap 和 reward alignment

这会成为最漂亮的理论-实验闭环。

情况 C: κ 改善, 但 α 朝不利方向移动

这实际上可能最有学术价值。

因为它直接解释:

9/9 $rESS \uparrow$

但只有:

8/9 $discrepancy \downarrow$.

也就是:

overlap improvement 与 reward-stratum movement 存在竞争。

这会非常强地支持：

$$m_2 = \kappa_2 A_\mu$$

不是装饰性 decomposition。

9. 一定要先看 target value 是否 $< 1/2$

由于：

$$\frac{\partial m_2}{\partial \alpha} = \kappa_2(1 - 2v),$$

α 的解释完全取决于：

$$v < 1/2 \quad \text{还是} \quad v > 1/2.$$

所以未来分析流程必须是：

先报 $\hat{v}_{\text{ref}} \rightarrow$ 再解释 $\Delta \hat{\alpha}$

不能先说：

alpha 下降是好事。

它不一定。

例如：

$$v < 1/2$$

时：

$$\alpha \downarrow$$

才降低该 reward-allocation factor;

而：

$$v > 1/2$$

时方向相反。

这个理论已经是 v10 很有特色的地方，数据出来后一定要正确利用。

10. prefix second-moment 理论是否需要补数值实验?

这是 v10 新增 A 以后最容易产生的问题。

我的建议：

有条件就做，但优先级低于 **Program 08** 和 $\hat{\alpha}$ 。

理论已经说明 sequence-level mismatch 如何通过：

$$\kappa_{2,t} = \kappa_{2,t-1} E_{\nu_{t-1}^{(2)}} [c_t]$$

递推。

真正完美的实验当然是估算 conditional full-vocabulary：

$$d_{2,t}(h) = D_2(\pi_t(\cdot|h) \parallel \mu_t(\cdot|h)).$$

但是这需要 full logits，计算代价不小。

没必要为了这篇论文重新做一个几十小时任务。

如果现有 rescore artifacts 保存了 tokenwise behavior / target logprob，那么可以零模型生成成本地计算 prefix：

$$W_{ij,t} = \exp \left\{ \sum_{s \leq t} \log \frac{\pi(a_s|h_{s-1})}{\mu(a_s|h_{s-1})} \right\}$$

然后：

$$\hat{\kappa}_{2,t} = \frac{1}{K} \sum_j W_{ij,t}^2.$$

再画：

$$t \rightarrow \widehat{rESS}_t.$$

这是一张很有解释力的 exploratory plot。

但一定叫：

empirical prefix second-moment diagnostic

不要叫：

token Rényi divergence estimate.

11. 如果做 prefix 图，最好放 Appendix，不要再抢正文

v10 的正文理论已经比较多。

所以我会把 prefix empirical figure 放：

Appendix: Prefix accumulation diagnostics.

正文 Section 4 的 Proposition 只保留理论。

Introduction/Discussion 一句指向 Appendix：

Consistent with the prefix recursion, the supplementary diagnostics show how empirical squared-weight concentration accumulates along completion prefixes.

如果结果不漂亮，甚至完全不需要加入。

理论本身仍然成立。

12. Program 08 完成后，Limitations 要有明显升级

当前 Limitations 正确地写：

no cross-dataset or model-scale robustness claim; external prompt-distribution robustness is outside current evidence.

Program 08 完成以后，这一句必须改。

如果 SVAMP 支持主要结论：

The external SVAMP experiment extends the evidence across prompt distributions, but not across model scales, training algorithms, reward types, or independently trained task-specific policies.

注意：

SVAMP 解决 prompt-distribution robustness $\neq$ model-scale robustness.

这个 distinction 一定保留。

13. 如果 SVAMP 不复制 GSM8K，论文并不会失败

这一点我认为特别重要。

因为实验是在冻结设计下做的。

假设结果是：

- high/medium/low overlap ordering 仍然存在；
- 但 refresh discrepancy improvement 不明显。

那么可以写：

Overlap structure transfers more reliably than discrepancy improvement.

这其实和你的理论高度一致：

$$m_2 = \kappa_2 A.$$

说明：

$$\kappa_2$$

的结构跨数据域比较稳定，

而：

$$A$$

或 reward prevalence / reference noise 更 task-specific。

这是非常好的结果。

如果更差，SVAMP 连 overlap ranking 都不保持：

那就写：

Historical-trace reuse is prompt-distribution dependent.

这会收窄 claim，但提高可信度。

而且因为这个实验是：

frozen beforehand

negative external result 本身就具有很高价值。

绝对不要因为结果不好而去重新挑 **pairs**。

14. 我建议事先把 Program 08 的解释规则锁死

在最终结果出来以前，最好现在就明确三个判断层级：

Level 1 – structural transfer

看：

low/medium/high overlap ordering

是否保持。

Level 2 – refresh transfer

看 recent vs old:

$$\Delta rESS$$

以及 discrepancy/RMSE。

Level 3 – decision-rule transfer

看 frozen gate:

coverage / false acceptance.

这样无论结果如何，我们都按这三个层级报告。

这能避免以后“挑最漂亮数字”。

15. Program 09 的作用：不是新科研实验，而是 final evidence freeze

Program 08 完成后，要重新跑最终 Program 09:

--require-svamp

让最终:

- main tables;
- figures;
- paper_values.json;
- manifest

都把 SVAMP 纳入。

这一步的学术价值是 **provenance**。

文章最终所有数字不要手工复制:

Program 08 raw outcome → Program 09 deterministic paper layer → LaTeX/PDF

当前 Data and Code Availability 已经强调 frozen config、registries、amendments、identity checks、machine-readable tables 和 deterministic paper-output layer。

Program 08 完成以后，这一段可以升级成:

External SVAMP outputs are generated under the same provenance chain and incorporated only through the frozen paper-output layer.

这是很好的 reproducibility 信号。

16. Appendix 应该承担大多数新增 SVAMP 细节

正文不要变成 25 页实验报告。

正文：

- 一个 subsection;
- 一个 summary table;
- 一个 figure。

Appendix 放：

- 所有 24 frozen SVAMP cases;
- seed-by-seed;
- overlap-band breakdown;
- gate full table;
- signed discrepancy;
- IS/pWIS detailed comparison (如果有);
- Program 08 amendment;
- FP32 repair explanation;
- exact pair registry;
- manifest hashes。

特别是那个 FP32 correctness repair, 一定要透明记录。

正文一句：


A pre-analysis implementation audit identified a precision-contract mismatch before any SVAMP OPE or reference outcomes were generated; the repaired run inherited the main experiment's FP32 generation/scoring contract. Full chronology is in Appendix X.

这不会减分。

反而体现 protocol firewall。

17. 最终文章中最好增加一个 “Evidence hierarchy” 图或表，而不是再加数学

等所有实验完成以后，我很推荐在 Introduction 或 Appendix 增加一个很简单的 evidence hierarchy:



并标出：

- calibration allowed where;
- pair selection allowed where;
- gate frozen where;
- no retuning after what point.

这比再加一个 theorem 更能让 reviewer 相信结果。

18. 最终 Discussion 应该从“两机制”升级成“三层证据”

Program 08 + alpha 完成后，我建议 Discussion 最重要的 3 段变成：

第一段：historical evidence ages structurally

GSM8K + SVAMP 都显示什么。

这对应：

$$\kappa_2.$$

第二段：refresh is two-channel

对应：

$$\kappa_2 \times [v^2 + (1 - 2v)\alpha].$$

如果 alpha analysis 有信息，直接解释具体数据。

第三段：diagnostics $\neq$ certificate

GSM8K gate + SVAMP gate 联合说明：

overlap 是必要的 evidence-quality coordinate，但单标量 threshold 不足以成为 universal deployment certificate。

这会让论文 Discussion 很有力量。

19. Conclusion 到时候只增加一件真正新的东西

不要重写全文。

最终增加类似：

The frozen SVAMP evaluation further shows [exact outcome], indicating that [the overlap mechanism / matched-refresh effect / gate limitation] does or does not transfer across prompt distributions.

然后继续强调：

not yet model-scale generalization.

即可。

20. 我给未来所有尚未完成工作按“学术价值 / 计算成本”排序

后续工作	计算成本	对论文价值	最终建议
完成 corrected Program 08 / SVAMP	高	极高	必须完成，如果计算能承受
Program 09 final freeze with SVAMP	很低	极高 (reproducibility)	必须
$\hat{\alpha}$ / reward-stratum analysis	极低	极高 (理论闭环)	强烈建议
matched squared discrepancy / RMSE	极低	高	建议
prefix $\hat{\kappa}_{2,t}$ full-vocabulary	低，如果 token scores 已有中/高	中高 中	有数据就做 不值得专门重跑
token D_2			
新 gate using α	低计算但协议风险高	中	只能 exploratory, 不能当 frozen test
第二个新外部 dataset	高	低-中	不要
更大模型整套重跑	极高	高但性价比差	这篇论文目前不必
新 estimator	高研究成本	可能使文章散掉	不要
调整 frozen gate	—	负价值	绝对不要

21. 最重要的最终路线

我认为最终文章最强版本不是：

GSM8K + SVAMP + 很多表格 + 很多 theorem。

而应该是：

Mechanism

autoregressive trajectory 中 second-moment overlap 如何形成；

Controlled evidence

GSM8K fixed-log + matched refresh；

Mechanistic explanation

κ_2 与 binary reward-stratum α ；

Measurement clarification

shared finite-reference identity；

External falsification

完全冻结的 SVAMP transfer；

Operational boundary

scalar rESS gate 不足。

这样文章就不再只是：

“我做了一个 OPE 实验。”

而会形成一个非常完整的研究命题：

Historical reasoning traces age through autoregressive second-moment concentration; refreshing the behavior evidence can restore support, but estimation risk additionally depends on where squared weight falls relative to reward outcomes. These mechanisms can be audited from logged traces, while a frozen cross-distribution test determines how far the reuse pattern transfers.

我认为这就是 Program 08 和剩余低成本分析完成以后，最大化这篇文章学术价值的最终形态。现阶段则不要为了“完整”再启动新的大型实验线。