

Historical GRPO Trace Reuse 最终整合备忘录

对 *When Can Historical GRPO Reasoning Traces Be Reused?* 最终稿的综合评估、核对与后续顶级期刊路线

Shenggang Li Independent Researcher

归档日期: 2026-09-13

归档说明。本备忘录以最终论文 `GRPO_Historical_Trace_Reuse_final.pdf`、冻结的 GSM8K 主实验、SVAMP external stress test、Program 09 deterministic paper layer, 以及 post-hoc α mechanism analysis v2 为依据, 记录最终论文整合后最重要的学术变化、数值结论、通盘检查、评分以及后续研究方向。当前归档版最终论文 SHA-256 为:

7bb24c0c9ae99031566373239e02afde9e309be1ef373a8136aa933a8b8bac6e

1 最终整合的核心变化

最终论文不是简单地在原稿上“增加一个 SVAMP 数据集”, 而是把整篇文章的证据结构升级为:

development $\rightarrow$ held-out training seed $\rightarrow$ official GSM8K test $\rightarrow$ frozen SVAMP external test.

这一结构把研究从单一数据域内的 controlled audit, 提升为带有明确 protocol firewall 的两阶段证据体系。GSM8K 负责建立并冻结主要现象、matched-refresh comparison 和 scalar gate; SVAMP 不重新选 pair、不重调 estimator、不重新拟合 gate, 而是作为 external prompt-distribution falsification / stress test。

因此最终文章的主线可以概括为三层:

1. historical evidence 会随着 checkpoint drift 发生结构性老化;
2. recent behavior evidence 能在固定 target 下显著恢复 overlap, 并通常改善 finite-reference discrepancy;
3. overlap diagnostic 本身很重要, 但单一 scalar rESS threshold 并不能成为跨域的 discrepancy certificate。

2 SVAMP 外部验证进入正文后的主要结论

最终稿新增完整的 external robustness subsection, 并按预先冻结的三个问题报告: structural transfer、refresh transfer 和 decision-rule transfer。

2.1 Structural transfer

SVAMP 上预冻结 low/medium/high overlap bands 的 mean median-rESS 为

0.1378, 0.2118, 0.9743,

三个 seed 均保持

$$\text{rESS}_{\text{high}} > \text{rESS}_{\text{medium}} > \text{rESS}_{\text{low}}.$$

这说明 checkpoint-derived evidence staleness 并不是 GSM8K test-set 特有现象，而能够在新的 prompt distribution 上保留清晰的结构排序。

2.2 Matched refresh transfer

SVAMP 的六个 frozen matched comparisons 中，同一 target 用 old behavior log 与 recent behavior log 评估时，mean median-rESS 从

$$0.14197 \rightarrow 0.96508,$$

并且 recent log 在

$$6/6$$

comparisons 中均具有更高 overlap。

Mean absolute reference discrepancy 从

$$0.008557 \rightarrow 0.002300,$$

下降约

$$73.1\%,$$

其中

$$5/6$$

matched cases 改善。RMSE 从

$$0.010296 \rightarrow 0.002541,$$

下降约

$$75.3\%.$$

这和 GSM8K official test 上的

$$0.127 \rightarrow 0.959, \quad 9/9 \text{ overlap improved},$$

以及

$$0.00587 \rightarrow 0.00164, \quad 8/9 \text{ absolute discrepancy improved}$$

形成非常清楚的外部复制关系。

2.3 Frozen scalar gate 的跨域负结果

SVAMP 上 frozen rESS gate 保持 100% acceptance, 但 false-acceptance behavior 显示:

Tolerance ϵ	0.01	0.02	0.05
Acceptance rate	100%	100%	100%
False-accept rate	25.0%	4.17%	0%

GSM8K official test 在 1% tolerance 下已经有 15.2% false acceptance; SVAMP 中进一步出现 25.0%。因此最终文章最有价值的 negative result 之一是:

mechanism transfers, but the scalar decision certificate does not.

换言之, rESS 是稳定而有用的 evidence-quality coordinate, 但一个 frozen scalar threshold 不能被解释为普适的 discrepancy-safe deployment certificate。

3 α / reward-stratum mechanism analysis 的最终作用

论文理论部分具有

$$m_2 = \kappa_2 A_\mu$$

的 overlap–reward-residual decomposition。对于 binary correctness reward, 进一步有

$$A_\mu = v^2 + (1 - 2v)\alpha_\mu.$$

最新的 post-hoc analysis v2 第一次用已有 completion-level rescoring artifacts 对这两个通道进行实证分解。

该分析严格标记为 **post-hoc exploratory mechanism analysis**: development matched pairs 是主要 exploratory layer, official test 只作为 exploratory replication, 而不是 confirmatory theorem validation。

所有匹配的 GSM8K target reference values 均满足

$$\hat{v}_{\text{ref}} < \frac{1}{2},$$

所以

$$\frac{\partial m_2}{\partial \alpha} = \kappa_2(1 - 2v) > 0.$$

在这个区域, α 降低才是 locally favorable movement。

但实际平均 α 变化为

development: 0.04850 $\rightarrow$ 0.05094,

official test: 0.04016 $\rightarrow$ 0.04589,

只有

18/45 和 2/9

matched pairs 的 α 朝有利方向移动。

与此同时, 按照 prompt-average estimator 对应的 arithmetic aggregation, aggregate empirical leading-risk proxy 在

45/45

development cases 和

9/9

official-test cases 中全部改善。因此数据支持预先定义的 Scenario C:

overlap restoration dominates adverse reward-stratum movement.

这使 $m_2 = \kappa_2 A_\mu$ 不再只是装饰性的理论分解: refresh 可以让 overlap 通道大幅改善, 同时 reward-stratum allocation 通道轻微朝相反方向变化; 总体 leading-risk proxy 仍由 overlap gain 主导。

4 最终 Discussion 与 Limitations 的升级

最终 Discussion 现在可以分成四个互相衔接的层次:

1. **Historical evidence ages structurally.** GSM8K 与 SVAMP 共同显示 checkpoint drift 导致 overlap deterioration。
2. **Refresh is a two-channel operation.** refresh 不保证 κ_2 与 A_μ 同时朝有利方向变化。
3. **Finite references are measurement devices, not truth.** shared finite-reference identity 解释 expected squared comparison, 但不把有限 Monte Carlo reference 变成 exact policy value。
4. **Diagnostics are not certificates.** overlap diagnostics 对解释 evidence quality 很有价值, 但单标量 threshold 不足以承担 universal deployment certification。

Limitations 也发生实质变化。原来“没有 cross-dataset evidence”的限制已经被 SVAMP 部分解决, 因此当前更准确的边界是:

The frozen SVAMP experiment extends the evidence across prompt distributions, but not across model scales, training algorithms, reward types, or independently trained task-specific policies.

这一区分很重要。SVAMP 是新的 prompt distribution, 但仍使用同一批 GRPO-trained checkpoints, 因此它不等价于 independent-policy-family generalization, 也不等价于 model-scale robustness。

5 Reproducibility 与 protocol provenance

最终论文保留并加强了 protocol provenance:

- SVAMP 的 pair selection、estimator、probability scoring 和 frozen gate 均在查看最终 external outcomes 前锁定;

- pre-analysis audit 发现 precision-contract mismatch 后, corrected external run 继承主实验 FP32 generation/scoring contract;
- Program 08 raw external outcomes 通过 manifest 和 hashes 进入 Program 09 deterministic paper-output layer;
- Program 09 不调用模型、不重新拟合 gate、不修改 upstream results;
- post-hoc α analysis v2 只读取现有 artifacts, 不调用模型、不使用 CUDA、不改变 frozen evidence;
- 最终 manuscript 中新增数值以 machine-readable outputs 为来源, 而不是人工抄写建立新的结果链。

这种 provenance discipline 是当前稿件最强的方面之一, 也应该在 GitHub/reproducibility package 中继续保留。

6 最终通盘检查

最终论文经过逐页 render/preflight 检查。主要核对项目包括:

- Abstract、Introduction、Theory、Experiments、Results、Discussion、Limitations、Conclusion 之间的 claims 一致;
- GSM8K 和 SVAMP 的 finite on-policy comparisons 统一使用 *reference discrepancy*, 没有把 finite reference 写成 exact truth;
- 所有六张主要图和主要表格无裁切、重叠、黑块或横向越界;
- 新增 SVAMP 表图与原有视觉逻辑一致;
- α analysis 明确标注 exploratory, 不与 frozen confirmatory evidence 混淆;
- 关键数字逐项复核, 包括 GSM8K $0.127 \rightarrow 0.959$ 、SVAMP $0.142 \rightarrow 0.965$ 、SVAMP MAE reduction 73.1%、SVAMP 1% gate false acceptance 25.0%, 以及 aggregate m_2^{proxy} 的 45/45 与 9/9 improvement;
- 最终编译没有 undefined references/citations 或实质性的 overfull layout failure。

7 最终稿评分

下面的评分以严格同行评议的 ML/RL/OPE 论文为标准, 而不是一般 preprint 标准。

维度	评分 / 10	评价
研究问题的重要性	9.3	LLM-RL 持续产生昂贵 historical traces, 可信复用具有直接研究与工程价值。
问题定位与主线	9.4	fixed-log → matched refresh → external falsification → operational boundary 清楚。
理论严谨性	8.8	standard SNIS foundation 与 trace-specific consequences 区分明确。
理论原创性	8.4	强项是问题特化和机制组合, 不是新的 generic IS theory。
实验设计	9.5	chronological firewall、frozen gate、official test、external frozen stress test 很强。
内部有效性	9.3	exact rescoring、same-target matched design、shared reference、三条 independent paths。
外部有效性	7.9	SVAMP 显著增强, 但仍缺 independent models / policy families。
统计语言与 claim discipline	9.5	finite-reference、post-hoc、descriptive pair counts 均保持克制。
Negative-result 利用	9.5	gate failure 被转化为有价值的科学结论。
Reproducibility / provenance	9.7	当前论文最强部分之一。
写作与结构	9.2	已形成完整研究论文, 而不是逐步实验记录。
图表与可读性	9.1	external summary 与 Figure 6 强化两域比较。
综合论文质量	8.9	已达到很强的投稿稿件水平。
当前“顶级杂志”准备度	7.8	最大缺口是 breadth、independent generalization 和 stronger deployment theory。

综合质量和顶级杂志准备度需要分开理解。当前工作在内部一致性、protocol integrity、negative result 和 theory-experiment linkage 上已经很强；顶级期刊最可能追问的是：

Is this a mechanism demonstrated in one small-model GRPO laboratory, or a generally useful principle of LLM-RL evidence reuse?

SVAMP 已经回答了其中一部分, 但还没有覆盖 model family、model scale、training objective 与 reward type。

8 未来拓展与深化研究方向

8.1 第一优先级: independent model × task replication

下一阶段最有价值的扩展不是再增加一个类似 SVAMP 的 prompt dataset, 而是引入 independently trained policy paths。理想设计至少覆盖两个不同 scale 或 family, 并让其中至少一个在另一 reasoning task

上独立训练自己的 RL trajectory。真正强的外部结论应当是：不同训练轨迹仍显示

stale overlap $\rightarrow$ refresh recovery,

而不是仅仅把当前 checkpoints 投射到更多 prompt sets。

8.2 第二优先级：uncertainty-aware reuse certificate

当前 scalar rESS gate 的失败很有价值，因为它直接指出下一篇方法论文的方向。未来 rule 应联合使用 overlap、reward-residual structure、denominator concentration 和 finite-reference uncertainty，例如围绕

κ_2 , A_μ , weight-tail concentration, reference uncertainty

建立 finite-sample / high-confidence reuse criterion。关键原则是新的 certificate 必须预注册并在新的 external paths 上冻结验证，而不是在当前 test/SVAMP 结果上事后调 threshold。

8.3 第三优先级：prefix second-moment mechanism validation

理论中的 prefix recursion 目前很漂亮，但经验侧主要仍观察 terminal sequence weights。下一阶段可在受控子集中保存 full-vocabulary logits，直接估计或近似

$$d_{2,t}(h) = D_2(\pi_t(\cdot | h) \| \mu_t(\cdot | h))$$

或高质量 prefix second-moment process，从而验证 mismatch 如何沿 autoregressive horizon 累积。

8.4 其他高价值扩展

后续还包括：

- 从 binary correctness 扩展到 continuous verifier score、process reward、preference reward，并研究一般

$$A_\mu = \mathbb{E}_{\nu_2}(R - v)^2;$$

- 扩展到 multi-turn / tool-agent trajectories，其中 horizon 更长、support deterioration 可能更严重；
- 把 evidence refresh 建模成有成本的 sequential decision problem，在

reuse, partial refresh, full resample

之间权衡 sampling cost 与 uncertainty constraint；

- 建立公开 historical-trace reuse benchmark，包括 checkpoint paths、pair registries、manifests、frozen external protocol 与 machine-readable outputs。

9 顶级期刊路线的三项核心投入

如果下一阶段只允许投入三项工作，优先顺序建议为：

independent model/task replication + uncertainty-aware reuse certificate + prefix-mechanism validation

不建议优先把资源投入到更多 estimator rankings、第三个类似 SVAMP 的数据集，或者重新调整现有 scalar gate。当前论文已经较好回答了“现象是否存在、机制是否具有结构、简单 rule 为什么不够”；顶级期刊版本下一步真正需要回答的是：

这一机制有多普遍，以及能否从该机制发展出具有理论保证、可部署的 evidence-management principle。

结论

最终稿已经从一个单域 controlled OPE study，升级为具有 frozen external validation、mechanism post-processing 和严格 provenance chain 的完整研究论文。其当前最强优势是实验协议纪律、matched fixed-target design、negative-result interpretation，以及 overlap-reward-residual mechanism 与 empirical evidence 的结合。下一阶段如果能够跨独立模型/任务复现，并进一步建立 uncertainty-aware reuse certificate，这一工作有潜力从“高质量单篇论文”发展为一个持续的 LLM-RL evidence management 研究方向。